

GEO 基因表达差异分析文献复现报告

2026 年 06 月 04 日

摘要

目的：

用 Python 复现 Gene Expression Omnibus (GEO) 数据库中的数据集中 GSE18312，对比复现结论与研究者的原始研究结论是否一致。

方法：

在 GEO 数据库中检索关于精神分裂症和双相情感障碍患者血液中的基因表达的数据集 GSE18312。使用 Python 中的 Jupyter Notebook 读取数据集数据、提取并重新构建分组信息。采用独立样本 t 检验比较疾病组（精神分裂症+双相情感障碍，22 例）与对照组（8 例）的基因表达差异，使用 Benjamini-Hochberg 法控制假发现率（FDR）以校正多重假设检验。计算 $\log_2$ 倍数变化 ($\log_2FC$)。使用 Wilcoxon 秩和检验进行非参数验证。用火山图、热图等将对分析结果可视化。

结果：

未校正的 t 检验中，共发现 399 个基因的 p 值 <0.05 ，其中 6 个基因的 $|\log_2FC| > 1$ 。经 FDR 校正后（校正后 p 值，即 q 值 <0.05 ），未检测到统计学上显著的差异表达基因。Wilcoxon 检验同样未发现显著基因。

结论：

本复现结果与原始研究在个体基因表达差异水平上得出的研究结果一致，均未发现经多重校正后的显著差异表达基因。

关键词： 基因差异表达分析；精神分裂症；双相情感障碍；GEO 数据库；复现研究

目 录

摘 要.....	I
目 录.....	II
引 言.....	1
复现过程.....	2
1.1 运行环境.....	2
1.2 复现对象.....	2
1.3 数据集信息.....	2
1.3.1 数据集标题 (Title)	2
1.3.2 数据集组织来源 (Organism)	2
1.3.3 数据集实验类型 (Experiment Type)	2
1.3.4 数据集简介 (Summary)	2
1.4 复现代码.....	3
1.4.1 数据集获取.....	3
1.4.2 寻找“ID_REF”的位置.....	3
1.4.3 读取数据集.....	4
1.4.4 提取样本分组/诊断信息.....	4
1.4.5 构建样本分组信息.....	5
1.4.6 基因差异表达分析 (t 检验+使用 FDR 校正)	5
1.4.7 基因差异表达分析 (t 检验+不使用 FDR 校正)	7
1.4.8 整理候选基因列表并绘制热图.....	9
1.5 统计分析.....	10
1.6 复现结果.....	11
1.6.1 数据集获取.....	11
1.6.2 寻找“ID_REF”的位置.....	12
1.6.3 读取数据集.....	12
1.6.4 提取样本分组/诊断信息.....	13
1.6.5 构建样本分组信息.....	13
1.6.6 基因差异表达分析 (t 检验+使用 FDR 校正)	14
1.6.7 基因差异表达分析 (t 检验+不使用 FDR 校正)	14
1.6.8 整理候选基因列表并绘制热图.....	15
1.7 讨论与展望.....	16
1.8 结论.....	17
参考文献.....	18

引言

精神分裂症（Schizophrenia, SCZ）和双相情感障碍（Bipolar Disorder, BPD）共同影响 1.5%的人口,被视为两种最严重且最具破坏性的精神疾病[Merikangas et al., 2007; Saha et al., 2008]。与囊性纤维化等许多具有已知遗传病因和血液、组织或其他确证性检测的遗传性疾病不同,精神分裂症和双相情感障碍等复杂疾病已被证明难以归类,且目前尚无客观诊断工具[Bearden et al., 2004]。

尽管基因关联研究和表达研究已经指出许多基因与精神分裂症（SCZ）和双相情感障碍（BPD）的病因有关,但大多数研究结果未能得到重复验证,或缺乏荟萃分析（Meta 分析）的支持。因此,要为这两种疾病开发客观的诊断工具,一个可行的策略是:找出在这些疾病中表现出失调的差异表达基因网络或通路。随后,可以从这些失调最严重的网络中提取潜在的候选基因,并进一步探究其在病因学上的重要意义。如果在精神分裂症、双相情感障碍患者以及有患病风险的家族成员中成功识别出这类生物标志物,将有望彻底改变这些疾病的治疗模式,并改善患者的预后。这也将通过规范目前的初诊和鉴别诊断流程,对全球公共卫生产生深远影响——要知道,现有的诊断过程往往需要耗费大量的时间、精力,且充满不确定性。

有研究团队[Bousman CA et al., 2009]报告一项探索性通路分析研究。该分析研究的数据来源于两项独立的外周血微阵列研究（这两项研究分别在美国圣地亚哥和中国台湾开展,在地理位置、受试者招募方式以及遗传背景上均相互独立）,研究对象涵盖精神分裂症（SCZ）、双相情感障碍（BPD）及精神病患者。在这些研究中,我们发现了泛素-蛋白酶体系统（UPS）受损的初步证据。

本研究以基于上述探索性通路分析研究成果的、收载于 Gene Expression Omnibus（GEO）数据库中的、关于精神分裂症和双相情感障碍患者血液中的基因表达的数据集 GSE18312 为对象,使用 Python 对数据集的个体基因表达差异水平进行分析,对比复现结论与研究者的原始研究结论是否一致。

复现过程

1.1 运行环境

操作系统: Windows 8 64 位; Python 版本: v3.8.10; Visual Studio Code 版本: v1.79.2。

其他插件及版本: Numpy: v1.24.3; Pandas: v2.0.3; Matplotlib: v3.7.5; Jupyter: v2023.5.1101742258。

1.2 复现对象

数据集: GSE18312。

数据集来源: GEO 数据库 (Gene Expression Omnibus)。

数据库网址: <https://www.ncbi.nlm.nih.gov/geo/>。

1.3 数据集信息

1.3.1 数据集标题 (Title)

精神分裂症和双相情感障碍患者血液中的基因表达 (Gene Expression in Blood in Schizophrenia and Bipolar Disorder)。

1.3.2 数据集组织来源 (Organism)

智人 (Homo sapiens)。

1.3.3 数据集实验类型 (Experiment Type)

基于芯片技术的基因表达谱数据 (Expression profiling by array)。“Expression profiling”表示基因表达谱分析,“by array”表示使用微阵列 (Microarray) 技术,即芯片技术。

1.3.4 数据集简介 (Summary)

Schizophrenia (SCZ) and bipolar disorder (BPD) are polygenic disorders with many genes contributing to their etiologies. The aim of this investigation was to search for dysregulated molecular and cellular pathways for these disorders as well as psychosis. We conducted a blood-based microarray investigation in two independent samples with SCZ and BPD from San Diego (SCZ=13, BPD=9, control=8) and Taiwan [data not included](SCZ=11, BPD=14, control=16). Diagnostic groups were compared to controls, and subjects with a history of psychosis [PSYCH(+): San Diego (n=6), Taiwan (n=14)] were compared to subjects without such history [PSYCH(-): San Diego (n=11), Taiwan (n=14)]. Analyses of covariance comparing mean expression levels on a gene-by-gene basis were conducted to generate the top 100 significantly dysregulated gene lists for both samples by each diagnostic group. Gene lists were imported into Ingenuity Pathway Analysis (IPA) software. Results showed the ubiquitin proteasome pathway (UPS) was listed in the top ten canonical pathways for BPD and psychosis diagnostic groups across

both samples with a considerably low likelihood of a chance occurrence ($p = .001$). No overlap in dysregulated genes populating these pathways was observed between the two independent samples. Findings provide preliminary evidence of UPS dysregulation in BPD and psychosis as well as support further investigation of the UPS and other molecular and cellular pathways for potential biomarkers for SCZ, BPD, and/or psychosis.

The aim of this investigation was to search for dysregulated molecular and cellular pathways for these disorders as well as psychosis.

精神分裂症（SCZ）和双相情感障碍（BPD）是具有多基因病因的复杂性状疾病。本研究旨在寻找这些疾病以及精神病中失调的分子和细胞通路。我们在圣地亚哥（SCZ=13, BPD=9, 对照组=8）和中国台湾省（数据未包含）（SCZ=11, BPD=14, 对照组=16）的两个独立样本中进行了基于血液的微阵列研究。将诊断组与对照组进行比较, 并将有精神病病史的受试者[PSYCH(+): 圣地亚哥(n=6), 中国台湾省(n=14)]与无此病史的受试者[PSYCH(-): 圣地亚哥(n=11), 中国台湾省(n=14)]进行比较。通过逐个基因比较平均表达水平, 进行协方差分析, 以生成每个诊断组在两个样本中的前 100 个显著失调基因列表。将基因列表导入 Ingenuity Pathway Analysis (IPA) 软件。结果显示, 在两个样本中, 泛素-蛋白酶体途径 (UPS) 均位列 BPD 和精神病诊断组的前十大典型途径, 且偶然发生的可能性相当低 ($p=0.001$)。在两个独立样本中, 这些途径中的失调基因没有重叠。研究结果为 UPS 在 BPD 和精神病中的失调提供了初步证据, 并支持进一步研究 UPS 和其他分子和细胞通路, 以寻找 SCZ、BPD 和/或精神病的潜在生物标志物。

本研究旨在探寻这些疾病以及精神病中失调的分子和细胞通路。

1.4 复现代码

1.4.1 数据集获取

浏览器打开 GEO 数据库 (网址: <https://www.ncbi.nlm.nih.gov/geo/>), 右侧搜索框中输入数据集代号 “GSE18312”, 下载格式为 TXT 的 “Series Matrix File(s)”。

1.4.2 寻找 “ID_REF” 的位置

在 Python 中新建后缀名为 “.ipynb” 的文件, 在文件中导入 gzip 模块, 用命令读取数据集中 “ID_REF” 的位置。详细代码及注释如下:

```
# 第一段代码, 寻找 "ID_REF" 的位置
# 编码格式选用 UTF-8, 遇到的 UnicodeDecodeError 是因为 Windows 下 gzip.open 默认使用系统编码 (gbk),
# 而 GEO 文件里包含一些无法用 gbk 解码的字符 (比如特殊标点、非英文字母)。我们需要显式指定编码为 utf-8 或 latin-1
# GEO 的矩阵文件通常是压缩格式, 需要先用 gzip 模块打开。
```

```
import gzip
```

```

with gzip.open('GSE18312_series_matrix.txt.gz', 'rt', encoding='utf-8',
errors='replace') as f:
    for i, line in enumerate(f):
        if i < 200:
            print(f"{i}: {line.strip()[:100]}")    # 打印行号 + 前 100 个字符
        else:
            break

```

1.4.3 读取数据集

根据 1.4.2 项“寻找‘ID_REF’的位置”的代码运行结果，读取数据集。详细代码如下：

第二段代码，读取数据集

根据第一段代码的结果，“ID_REF”的位置在第 71 行，因此设定参数 skiprows=71，并输出结果

```
import pandas as pd
```

尝试读取，如果报错就把 skiprows 改大或改小

```

expr = pd.read_csv('GSE18312_series_matrix.txt.gz', sep='\t', skiprows=71,
index_col=0)
expr.head()

```

1.4.4 提取样本分组/诊断信息

根据 1.4.3 项“读取数据集”的代码运行结果，解析“!Sample_characteristics_ch1”这一行，提取出每个样本的诊断（Bipolar Disorder 或 Control）。详细代码如下：

第三段代码

需要运行一段新的代码，专门解析 !Sample_characteristics_ch1 这一行，提取出每个样本的诊断（Bipolar Disorder 或 Control）。

```
import gzip
```

```

diagnosis_list = []
with gzip.open('GSE18312_series_matrix.txt.gz', 'rt', encoding='utf-8',
errors='replace') as f:
    for line in f:
        if line.startswith('!Sample_characteristics_ch1') and 'diagnosis:' in
line:
            parts = line.strip().split('\t')
            # 第一个元素是标签，后面每个元素对应一个样本
            for cell in parts[1:]:
                if 'diagnosis:' in cell:
                    diag = cell.split('diagnosis:')[1].strip().strip('')

```

```

        diagnosis_list.append(diag)
    break # 找到后即停止

```

```

print(f"共解析到 {len(diagnosis_list)} 个样本")
for i, d in enumerate(diagnosis_list):
    print(f"样本{i+1}: {d}")

```

1.4.5 构建样本分组信息

根据 1.4.4 项“提取样本分组/诊断信息”的代码运行结果，将样本进行分组。详细代码如下：

第四段代码：构建分组列名（正确缩进）

```

sample_columns = expr.columns.tolist()
control_cols = []
case_cols = []

for i, diag in enumerate(diagnosis_list):
    gsm_id = sample_columns[i]
    if diag == 'Control':
        control_cols.append(gsm_id) # 注意缩进（4 个空格）
    else: # 'Bipolar Disorder' 或 'Schizophrenia'
        case_cols.append(gsm_id) # 注意缩进（4 个空格）

```

对照组(Control)有 8 个样本，疾病组(Bipolar + Schizophrenia)有 22 个样本

用 NumPy 将列表转换为数组，然后使用 .reshape() 方法重新排列成多行多列，使输出更美观。

```

import numpy as np

# 对照组 8 个样本 -> 2 行 4 列
control_arr = np.array(control_cols).reshape(2, 4)
print("对照组样本 (2 行 4 列):")
for row in control_arr:
    print(' '.join(row))

print("\n")

# 疾病组 22 个样本 -> 2 行 11 列
case_arr = np.array(case_cols).reshape(2, 11)
print("疾病组样本 (2 行 11 列):")
for row in case_arr:
    print(' '.join(row))

```

1.4.6 基因差异表达分析（t 检验+使用 FDR 校正）

根据 1.4.5 项“构建样本分组信息”的代码运行结果，使用独立样本 t 检验+使用

FDR 校正，对已分组的样本进行基因差异表达分析。以校正后 p 值（即 q 值）为对象，画出火山图。详细代码如下：

第五段代码，基因差异表达分析(t 检验+使用 FDR 校正)

```
import numpy as np
import pandas as pd
import scipy.stats as stats
import matplotlib.pyplot as plt
import seaborn as sns
from statsmodels.stats.multitest import fdr correction

# 假设 expr 已读取，control_cols 和 case_cols 已定义
# 提取表达矩阵（数值）
expr_values = expr.values # shape (n_genes, n_samples)

# 获取对照组和疾病组的表达矩阵
control_expr = expr[control_cols].values
case_expr = expr[case_cols].values

# 计算 log2FC（因为数据已是 log2 表达值，直接相减）
log2fc = np.mean(case_expr, axis=1) - np.mean(control_expr, axis=1)

# 计算 p 值（使用 t 检验）
pvals = np.array([stats.ttest_ind(case_expr[i], control_expr[i]).pvalue for i
in range(expr.shape[0])])

# FDR 校正
_, padj = fdr correction(pvals)

# 构建结果 DataFrame
res = pd.DataFrame({
    'log2FC': log2fc,
    'pvalue': pvals,
    'padj': padj
}, index=expr.index)

# 筛选显著差异基因（|log2FC| > 1 且 padj < 0.05）
sig = res[(abs(res.log2FC) > 1) & (res.padj < 0.05)]
sig = sig.sort_values('log2FC', ascending=False)
print(f"显著差异基因数量: {len(sig)}")

# 保存结果
res.to_csv('GSE18312_v2_debug01_all_genes_results.csv')
```

```

sig.to_csv('GSE18312_v2_debug01_significant_genes.csv')

# 画火山图
plt.figure(figsize=(10,6))
sns.scatterplot(data=res, x='log2FC', y=-np.log10(res.padj),
hue=(abs(res.log2FC)>1) & (res.padj<0.05), alpha=0.6)
plt.xlabel('log2 Fold Change')
plt.ylabel('-log10(adjusted p-value)')
plt.title('Volcano plot (Bipolar+Schizophrenia vs Control)')
plt.axhline(y=-np.log10(0.05), linestyle='--', color='gray')
plt.axvline(x=1, linestyle='--', color='gray')
plt.axvline(x=-1, linestyle='--', color='gray')
plt.savefig('GSE18312_v2_debug01_volcano.png', dpi=150)
plt.show()

```

1.4.7 基因差异表达分析（t 检验+不使用 FDR 校正）

根据 1.4.6 项“基因差异表达分析（t 检验+使用 FDR 校正）”的代码运行结果，使用独立样本 t 检验+不使用 FDR 校正，对已分组的样本重新进行基因差异表达分析。以 p 值为对象，画出火山图。详细代码如下：

```

# 第五段代码，基因差异表达分析
# 数据诊断和验算

```

```

# 检查 p 值和 log2FC 的分布
print("log2FC 范围:", res.log2FC.min(), "-", res.log2FC.max())
print("log2FC 绝对值 > 0.5 的基因数:", (abs(res.log2FC) > 0.5).sum())
print("log2FC 绝对值 > 1 的基因数:", (abs(res.log2FC) > 1).sum())
print("padj < 0.05 的基因数:", (res.padj < 0.05).sum())
print("padj < 0.1 的基因数:", (res.padj < 0.1).sum())

# 确认一下对照组和疾病组的样本是否正确：打印出样本数以及前几个样本名称。
print()
print("对照组样本:", control_cols[:5])
print("疾病组样本:", case_cols[:5])

# 检查未校正的 p 值
print()
print("未校正 p < 0.05 的基因数:", (res.pvalue < 0.05).sum())
print("同时满足 |log2FC|>1 且 p<0.05 的基因数:", ((abs(res.log2FC)>1) &
(res.pvalue<0.05)).sum())

# 放宽 FDR 阈值
# 尝试使用 padj < 0.25 或 padj < 0.1 作为阈值
print()
print("padj < 0.25 的基因数:", (res.padj < 0.25).sum())

```

```

print("|log2FC|>1 且 padj<0.25 的基因数:", ((abs(res.log2FC)>1) &
(res.padj<0.25)).sum())

# 如果仍然没有显著基因, 可以报告差异倍数最大的前几个基因
top_genes = res.nlargest(6, 'log2FC').index
print()
print("log2FC 最大的 6 个基因:", top_genes)

# 第五段代码, 基因差异表达分析(t 检验+不使用 FDR 校正)

import numpy as np
import pandas as pd
import scipy.stats as stats
import matplotlib.pyplot as plt
import seaborn as sns
from statsmodels.stats.multitest import fdrcorrection

# 假设 expr 已读取, control_cols 和 case_cols 已定义
# 提取表达矩阵 (数值)
expr_values = expr.values # shape (n_genes, n_samples)

# 获取对照组和疾病组的表达矩阵
control_expr = expr[control_cols].values
case_expr = expr[case_cols].values

# 计算 log2FC (因为数据已是 log2 表达值, 直接相减)
log2fc = np.mean(case_expr, axis=1) - np.mean(control_expr, axis=1)

# 计算 p 值 (使用 t 检验)
pvals = np.array([stats.ttest_ind(case_expr[i], control_expr[i]).pvalue for i
in range(expr.shape[0])])

# FDR 校正
_, padj = fdrcorrection(pvals)

# 构建结果 DataFrame
res = pd.DataFrame({
    'log2FC': log2fc,
    'pvalue': pvals,
    'padj': padj
}, index=expr.index)

# 筛选显著差异基因 (|log2FC| > 1 且 padj < 0.05)
sig = res[(abs(res.log2FC) > 1) & (res.padj < 0.05)]

```

```

sig = sig.sort_values('log2FC', ascending=False)
print(f"显著差异基因数量: {len(sig)}")

# 保存结果
res.to_csv('GSE18312_v2_debug02_all_genes_results.csv')
sig.to_csv('GSE18312_v2_debug02_significant_genes.csv')

# 画火山图（使用未校正的 p 值）
plt.figure(figsize=(10,6))
sns.scatterplot(data=res, x='log2FC', y=-np.log10(res.pvalue),
                hue=(abs(res.log2FC)>1) & (res.pvalue<0.05), alpha=0.6)
plt.xlabel('log2 Fold Change')
plt.ylabel('-log10(p-value)')
plt.title('Volcano plot (Bipolar+Schizophrenia vs Control)')
plt.axhline(y=-np.log10(0.05), linestyle='--', color='gray') # 水平线表示
# p=0.05 阈值
plt.axvline(x=1, linestyle='--', color='gray') # 垂直线表示
log2FC=1
plt.axvline(x=-1, linestyle='--', color='gray') # 垂直线表示
log2FC=-1
plt.savefig('GSE18312_v2_debug02_volcano_unadjusted.png',
            dpi=150) # 注意是 savefig, 不是 savetiff
plt.show()

```

1.4.8 整理候选基因列表并绘制热图

根据 1.4.6 项“基因差异表达分析（t 检验+使用 FDR 校正）”和 1.4.7 项“基因差异表达分析（t 检验+不使用 FDR 校正）”的代码运行结果，加入 Wilcoxon 秩和检验，整理候选基因列表，并以候选基因的 log₂FC 值为对象绘制热图。详细代码如下：
第六段代码，加入 Wilcoxon 检验，整理差异表达具有统计学差异的 6 个基因，并绘制热图

```

# 1. 尝试 Wilcoxon 检验
from scipy.stats import mannwhitneyu
from statsmodels.stats.multitest import fdr correction

pvals_w = []
for i in range(expr.shape[0]):
    _, p = mannwhitneyu(expr[case_cols].iloc[i], expr[control_cols].iloc[i],
                        alternative='two-sided')
    pvals_w.append(p)
_, padj_w = fdr correction(pvals_w)
print()
print(f"Wilcoxon 检验: padj<0.05 基因数: {sum(padj_w<0.05)}")

# 2. 候选基因（未校正）

```

```

candidate = res[(abs(res.log2FC)>1) & (res.pvalue<0.05)]
print()
print(f"候选差异基因数量: {len(candidate)}")
print(candidate[['log2FC', 'pvalue']])

# 3. 保存候选基因列表
candidate.to_csv('GSE18312_v2_candidate_genes.csv')

# 4. 提取表达量并画热图
candidate_expr = expr.loc[candidate.index]
order_cols = control_cols + case_cols
candidate_expr = candidate_expr[order_cols]

from scipy.stats import zscore
candidate_expr_z = candidate_expr.apply(zscore, axis=1)

plt.figure(figsize=(8,6))
sns.heatmap(candidate_expr_z, cmap='RdBu_r', center=0)
plt.title('Candidate genes (|log2FC|>1, p<0.05)')
plt.tight_layout()
plt.savefig('GSE18312_v2_candidate_heatmap.png', dpi=150)
plt.show()

```

1.5 统计分析

采用独立样本 t 检验比较疾病组与对照组的基因表达差异 (p 值)，使用 Benjamini-Hochberg 法控制假发现率 (FDR) 以校正多重假设检验 (校正后 p 值，即 q 值)。计算 $\log_2$ 倍数变化 ($\log_2FC$)。使用 Wilcoxon 秩和检验进行非参数验证。

$p < 0.05$ ，或 $q < 0.05$ ，或满足 $|\log_2FC| > 1$ 且 $q < 0.05$ ，或满足 $|\log_2FC| > 1$ 且 $q < 0.05$ ，视作统计学意义上具有显著性差异。

1.6 复现结果

1.6.1 数据集获取

在 GEO 数据库主页搜索数据集 “GSE18312”，详见图 1；并下载格式为 TXT 的 “Series Matrix File(s)”，详见图 2。




图 1 GEO 数据库主页




图 2 搜索结果及数据集 GSE18312 下载位置

1.6.2 寻找“ID_REF”的位置

代码运行结果表明，数据集的“ID_REF”位置在第 71 行。详见图 3。

```
60 59: !sample_data_processing "The data were analyzed with Partek Genomics Suite v6.4 using robust multich
61 60: !sample_platform_id "GPL1575" "GPL1575" "GPL1575" "GPL1575" "GPL1575" "GPL1575" "GPL1575"
62 61: !sample_contact_name "Ming,,Tsuang" "Ming,,Tsuang" "Ming,,Tsuang" "Ming,,Tsuang" "Ming,,Tsuang" "Ming,,Tsuang" "Min
63 62: !sample_contact_institute "UCSD" "UCSD" "UCSD" "UCSD" "UCSD" "UCSD" "UCSD" "UCSD" "UCSD" "UCSD"
64 63: !sample_contact_address "9500 Gilman Drive" "9500 Gilman Drive" "9500 Gilman Drive" "9500 Gilman Drive" "9500 Gilman Drive"
65 64: !sample_contact_city "La Jolla" "La Jolla" "La Jolla" "La Jolla" "La Jolla" "La Jolla" "La Jolla" "L
66 65: !sample_contact_state "CA" "CA" "CA" "CA" "CA" "CA" "CA" "CA" "CA" "CA" "CA" "CA" "CA" "CA" "CA"
67 66: !sample_contact_zip/postal_code "92093" "92093" "92093" "92093" "92093" "92093" "92093" "92093" "920
68 67: !sample_contact_country "USA" "USA" "USA" "USA" "USA" "USA" "USA" "USA" "USA" "USA" "USA" "USA"
69 68: !sample_supplementary_file "ftp://ftp.ncbi.nlm.nih.gov/geo/samples/GSM457nnn/GSM457192/suppl/GSM4571
70 69: !sample_data_row_count "21980" "21980" "21980" "21980" "21980" "21980" "21980" "21980" "2198
71 70: !series_matrix table begin
72 71: "ID_REF" "GSM457192" "GSM457193" "GSM457194" "GSM457195" "GSM457196" "GSM457197" "GSM457198" "GSM457
73 72: 2315554 6.5351 6.16573 6.08744 6.10136 6.04127 5.27559 6.01966 6.29819 6.45823 6.55044 6.23999 6.109
74 73: 2315633 7.17689 7.20575 6.82605 7.17285 7.05456 6.96293 7.20699 7.49971 7.30354 7.09737 7.53502 6.84
75 74: 2315674 6.55579 6.28588 5.95248 6.17761 6.13563 5.79059 5.99075 6.66728 6.25267 6.35095 6.44261 6.05
76 75: 2315739 6.86085 6.69799 6.43789 7.01026 6.54653 6.54662 6.64821 7.11046 6.65028 6.52463 6.86711 6.45
77 76: 2315894 9.17301 8.37226 8.13117 8.3539 8.05318 7.26426 7.96812 8.75056 8.65927 8.46595 8.75985 7.995
78 77: 2315918 4.77827 4.17123 4.03432 4.74448 5.04552 4.57112 5.12373 5.38708 5.36059 5.80031 5.52622 4.70
79 78: 2315951 7.77894 7.58342 7.21985 7.40852 7.01274 6.72059 7.50051 7.37595 7.25348 7.21083 7.50454 6.87
80 79: 2316218 6.15442 5.14378 5.20468 5.16842 5.27303 4.32858 5.52932 5.6279 5.70426 5.04734 5.78903 5.201
```

图 3 数据集 GSE18312 “ID_REF” 位置

1.6.3 读取数据集

代码运行结果表明，数据集成功读取。由于页面限制，输出结果仅显示部分数据。详见图 4。

	GSM457192	GSM457193	GSM457194	GSM457195	GSM457196	GSM457197	GSM457198	GSM457199	GSM457200	GSM457201	...	GSM457212	GSM457213
ID_REF													
2315554	6.53510	6.16573	6.08744	6.10136	6.04127	5.27559	6.01966	6.29819	6.45823	6.55044	...	5.47620	5.21544
2315633	7.17689	7.20575	6.82605	7.17285	7.05456	6.96293	7.20699	7.49971	7.30354	7.09737	...	6.95018	6.98808
2315674	6.55579	6.28588	5.95248	6.17761	6.13563	5.79059	5.99075	6.66728	6.25267	6.35095	...	5.61107	5.39586
2315739	6.86085	6.69799	6.43789	7.01026	6.54653	6.54662	6.64821	7.11046	6.65028	6.52463	...	6.57632	6.56805
2315894	9.17301	8.37226	8.13117	8.35390	8.05318	7.26426	7.96812	8.75056	8.65927	8.46595	...	7.59274	7.31548

5 rows × 30 columns

图 4 已读取的数据集 GSE18312（部分）

1.6.4 提取样本分组/诊断信息

代码运行结果表明，数据集中有 30 例样本。其中样本 1 至样本 9 为“Bipolar Disorder”，即双相情感障碍（BPD），共 9 例；样本 10 至样本 22 为“Schizophrenia”，即精神分裂症（SCZ），共 13 例；样本 23 至样本 30 为“Control”，共 8 例。详见图 5。

```
共解析到 30 个样本
样本1: Bipolar Disorder
样本2: Bipolar Disorder
样本3: Bipolar Disorder
样本4: Bipolar Disorder
样本5: Bipolar Disorder
样本6: Bipolar Disorder
样本7: Bipolar Disorder
样本8: Bipolar Disorder
样本9: Bipolar Disorder
样本10: Schizophrenia
样本11: Schizophrenia
样本12: Schizophrenia
样本13: Schizophrenia
样本14: Schizophrenia
样本15: Schizophrenia
样本16: Schizophrenia
样本17: Schizophrenia
样本18: Schizophrenia
样本19: Schizophrenia
样本20: Schizophrenia
样本21: Schizophrenia
样本22: Schizophrenia
样本23: Control
样本24: Control
...
样本27: Control
样本28: Control
样本29: Control
样本30: Control
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...
```

图 5 已提取的数据集 GSE18312 中样本分组/诊断信息

1.6.5 构建样本分组信息

代码运行结果表明，将数据集的 30 例样本分为 2 组。其中对照组样本 8 例（“Control”），疾病组样本 22 例（“Bipolar Disorder” 9 例+ “Schizophrenia” 13 例）。详见图 6。

```
对照组样本 (2行4列):
GSM457214 GSM457215 GSM457216 GSM457217
GSM457218 GSM457219 GSM457220 GSM457221

疾病组样本 (2行11列):
GSM457192 GSM457193 GSM457194 GSM457195 GSM457196 GSM457197 GSM457198 GSM457199 GSM457200 GSM457201 GSM457202
GSM457203 GSM457204 GSM457205 GSM457206 GSM457207 GSM457208 GSM457209 GSM457210 GSM457211 GSM457212 GSM457213
```

图 6 数据集 GSE18312 中 30 例样本分组情况

1.6.6 基因差异表达分析（t 检验+使用 FDR 校正）

代码运行结果表明，使用独立样本 t 检验并使用 FDR 校正后，两组样本之间，在表达水平上，具有显著性差异（满足 $|\log_2FC|>1$ 且 $q<0.05$ ）的基因数量为 0。详见图 7。




图 7 数据集 GSE18312 基因差异表达分析火山图（t 检验+使用 FDR 校正）

1.6.7 基因差异表达分析（t 检验+不使用 FDR 校正）

代码运行结果表明，使用独立样本 t 检验并不使用 FDR 校正，两组样本之间，在表达水平上，具有显著性差异（ $p<0.05$ ）的基因有 399 个；计算 $\log_2$ 倍数变化（ $\log_2FC$ ）后，具有显著性差异（满足 $|\log_2FC|>1$ 且 $p<0.05$ ）的基因有 6 个。详见图 8、图 9。

```
log2FC 范围: -1.1612755681818179 - 1.3066904545454534
log2FC 绝对值 > 0.5 的基因数: 129
log2FC 绝对值 > 1 的基因数: 6
padj < 0.05 的基因数: 0
padj < 0.1 的基因数: 0

对照组样本: ['GSM457214', 'GSM457215', 'GSM457216', 'GSM457217', 'GSM457218']
疾病组样本: ['GSM457192', 'GSM457193', 'GSM457194', 'GSM457195', 'GSM457196']

未校正 p < 0.05 的基因数: 399
同时满足  $|\log_2FC|>1$  且  $p<0.05$  的基因数: 6

padj < 0.25 的基因数: 0
 $|\log_2FC|>1$  且 padj<0.25 的基因数: 0

log2FC 最大的6个基因: Index(['2633191', '3392880', '3807502', '3335846', '2406353', '2775516'], dtype='object', name='ID_REF')
```

图 8 数据集 GSE18312 基因差异表达分析（t 检验+不使用 FDR 校正）计算结果




图 9 数据集 GSE18312 基因差异表达分析火山图（t 检验+不使用 FDR 校正）

1.6.8 整理候选基因列表并绘制热图

代码运行结果表明，使用 Wilcoxon 秩和检验后，两组样本之间，在表达水平上，具有显著性差异（ $q < 0.05$ ）的基因数量为 0。结合 1.6.7 项“基因差异表达分析（t 检验+不使用 FDR 校正）”的结果，确认仅在使用 t 检验+不使用 FDR 校正时，两组样本之间，在表达水平上，具有显著性差异（满足 $|\log_2 FC| > 1$ 且 $p < 0.05$ ）的基因有 6 个，可列为候选基因。详见图 10、图 11。

候选差异基因数量: 6

ID_REF	log2FC	pvalue
2633191	1.306690	0.015087
2844381	-1.043082	0.034800
3392880	1.095991	0.017301
3556735	-1.161276	0.008726
3725860	-1.060823	0.035064
3743542	-1.075861	0.001463

图 10 候选基因列表




图 11 候选基因 $\log_2FC$ 值热图

1.7 讨论与展望

本次复现，选取精神分裂症和双相情感障碍患者血液中的基因表达的数据集 GSE18312，使用 Python 读取数据集，将数据集的 30 例样本分为对照组样本 8 例、疾病组样本 22 例，依次采用独立样本 t 检验+使用 FDR 校正和独立样本 t 检验+不使用 FDR 校正，进行基因差异表达分析，计算 $\log_2$ 倍数变化 ($\log_2FC$)，使用 Wilcoxon 秩和检验进行非参数验证，最后用火山图、热图等将对分析结果可视化。

复现结果表明，采用独立样本 t 检验+使用 FDR 校正时，两组样本之间，在表达水平上，具有显著性差异（满足 $|\log_2FC|>1$ 且 $q<0.05$ ）的基因数量为 0。采用独立样本 t 检验+不使用 FDR 校正时，具有显著性差异 ($p<0.05$) 的基因有 399 个；计算 $\log_2$ 倍数变化 ($\log_2FC$) 后，具有显著性差异（满足 $|\log_2FC|>1$ 且 $p<0.05$ ）的基因有 6 个。使用 Wilcoxon 秩和检验进行非参数验证，两组样本之间，在表达水平上，具有显著性差异 ($q<0.05$) 的基因数量为 0。

本复现结果与原始研究在个体基因表达差异水平上得出的研究结果一致，均未发现经多重校正后的显著差异表达基因。

本次复现，使用独立样本 t 检验+使用 FDR 校正进行基因差异表达分析时发现，两组样本之间，在表达水平上，具有显著性差异（满足 $|\log_2FC|>1$ 且 $q<0.05$ ）的基因

数量为 0。原因可能有：

其一，数据集 GSE18312 仅有 30 例样本，在样本量较小的情况下，统计功效不足。其二，30 例样本中，对照组 8 例，疾病组 22 例。疾病组的 22 例样本中，又分为双向情感障碍 9 例、精神分裂症 13 例，样本数据的异质性可能进一步削弱差异。原始研究者在分析、上传和注释的过程，对于样本数据的预处理方式，同样可能对复现结果有影响。

本次复现仅聚焦于，疾病组与对照组之间的基因差异表达分析，未涉及症状关联分析（因数据缺失），也未进行通路富集分析。复现结果也提示，精神分裂症与双向情感障碍患者外周血转录组差异微弱，单一基因水平的差异难以通过多重假设检验，后续研究可侧重通路富集分析或扩大样本量以提高统计效能。

1.8 结论

本复现结果与原始研究在个体基因表达差异水平上得出的研究结果一致，均未发现经多重校正后的显著差异表达基因。

参考文献

- [1] Bousman CA, Chana G, Glatt SJ, Chandler SD, Lucero GR, Tatro E, May T, Lohr JB, Kremen WS, Tsuang MT, Everall IP. Preliminary evidence of ubiquitin proteasome system dysregulation in schizophrenia and bipolar disorder: convergent pathway analysis findings from two independent samples. *Am J Med Genet B Neuropsychiatr Genet*. 2010 Mar 5;153B(2):494-502. doi: 10.1002/ajmg.b.31006. PMID: 19582768; PMCID: PMC4165610.
- [2] Bousman CA, Chana G, Glatt SJ, Chandler SD, May T, Lohr J, Kremen WS, Tsuang MT, Everall IP. Positive symptoms of psychosis correlate with expression of ubiquitin proteasome genes in peripheral blood. *Am J Med Genet B Neuropsychiatr Genet*. 2010 Oct 5;153B(7):1336-41. doi: 10.1002/ajmg.b.31106. PMID: 20552680; PMCID: PMC4461056.